

EXERCÍCIO 02: SVM, kNN, DECISION TREE e CNN

Aluno: Wellington Braga

Turma: _____ Data: ____/____/ 2024

Questões relacionadas ao conteúdo da disciplina:

Questão 1. Suponha que você esteja trabalhando na previsão do tempo e use um algoritmo de aprendizado para prever a temperatura de amanhã (em graus Centígrados/Fahrenheit). Você trataria isso como uma classificação ou um problema de regressão?

Seria um problema de **regressão**, porque estamos prevendo um valor contínuo (a temperatura) em vez de categorias.

Questão 2. Alguns dos problemas abaixo são mais bem resolvidos usando um algoritmo de aprendizagem supervisionado, e os outros com um algoritmo não supervisionado. Qual dos seguintes você aplicaria aprendizagem supervisionada? (Selecione todas que se apliquem.) Em cada caso, suponha que um conjunto de dados adequado está disponível para o seu algoritmo aprender.

1. Examine uma página da Web e classifique se o conteúdo da página deve ser considerado "amigável para crianças" ou "adulto".
2. Dada uma base de dados sobre como 1.000 pacientes médicos respondem a um medicamento experimental (como eficácia do tratamento, efeitos colaterais, etc.), descubra se existem diferentes categorias ou "tipos" de pacientes em termos de como eles respondem ao medicamento e em caso afirmativo, quais são essas categorias.
3. Na agricultura, com dados sobre o rendimento das colheitas nos últimos 50 anos, aprenda a prever os rendimentos das colheitas do próximo ano.
4. Dado um grande conjunto de dados de registros médicos de pacientes que sofrem de doenças cardíacas, tente descobrir se pode haver diferentes grupos desses pacientes para os quais podemos adaptar tratamentos separados.

Questão 3. Supondo que haja uma base de dados suficientemente grande para o treinamento de algum algoritmo. Assim, treinar utilizando uma grande quantidade de dados normalmente resulta em uma boa performance. Marque verdadeiro ou falso nas afirmações e justifique sua resposta:

1. As características contêm informação suficiente para prever a saída corretamente.

Verdadeiro – Se as características (features) contêm informação suficiente e bem representada, o algoritmo pode aprender a prever a saída corretamente,

desde que tenha dados suficientes.

2. Não é necessário utilizar regularização.

Falso – Regularização continua sendo importante, mesmo com muitos dados, para evitar overfitting, especialmente se o modelo for muito complexo ou se houver ruído nos dados.



1

Reconhecimento de Padrões Exercício 02

Questão 4. Imagine que estamos trabalhando em um classificador de *spam*, onde *e-mails* de *spam* são exemplos positivos (saída igual a 1) e *e-mails* não *spam* são exemplos negativos (saída igual a zero). Nós temos uma base de dados de treinamento onde 99% dos *e-mails* não são *spam* e os outros 1% que são. Quais das afirmativas abaixo são verdadeiras?



1. Se predizermos tudo como não *spam*, a acurácia do classificador será 99%
2. Se predizermos tudo como não *spam*, nosso classificador terá uma sensibilidade (*recall*) igual a 0%.
3. Se predizermos tudo como *spam*, o classificador terá uma sensibilidade de 100% e uma precisão de 1%.
4. Se predizermos tudo como *spam*, o classificador terá uma sensibilidade de 0% e uma precisão de 99%.

Questão 5. Marque verdadeiro ou falso nas afirmativas abaixo.

1. Utilizar uma base de dados grande para o treinamento pode evitar o *overfitting* do classificador. (F)
2. Se ocorre o *underfitting* do algoritmo na base de treinamento, obter mais dados pode ajudar. (F)
3. O processo de análise manual dos exemplos que o algoritmo errou pode ajudar a sugerir os próximos passos para melhorar a performance do algoritmo (por exemplo, inserir novas características). (V)
4. É uma boa ideia gastar bastante tempo na construção de uma base de dados suficientemente grande, antes de construir a primeira versão do algoritmo de aprendizado de máquinas. (F)

Questão 6. A figura 1 apresenta a função de custo $J(\theta_0, \theta_1)$ ("Plot 2"), assim como o contorno da mesma função ("Plot 1"). Baseado nas figuras, verifique quais das afirmativas abaixo são verdadeiras.

Figura 1 – Plotes da função de custo $J(\theta_0, \theta_1)$



INSTITUTO FEDERAL
ESPÍRITO SANTO
Campus Serra

2

Reconhecimento de Padrões Exercício 02

1. Se partimos do ponto B, um algoritmo de gradiente descendente com um valor adequado de taxa de aprendizado ajudará a atingirmos o ponto A, onde a função de custo $J(\theta_0, \theta_1)$ possui seu valor máximo. (F)
2. Se partimos do ponto B, um algoritmo de gradiente descendente com um valor adequado de taxa de aprendizado ajudará a atingirmos o ponto A, onde a função de custo $J(\theta_0, \theta_1)$ possui seu valor mínimo. (V)
3. O ponto P (mínimo global no Plot 2) corresponde ao ponto A no Plot 1. (V)
4. Se partimos do ponto B, um algoritmo de gradiente descendente com um valor adequado de taxa de aprendizado ajudará a atingirmos o ponto C, onde a função de custo $J(\theta_0, \theta_1)$ possui seu valor mínimo. (F)
5. O ponto P (mínimo global no Plot 2) corresponde ao ponto C no Plot 1. (F)

Questão 7. Você roda um algoritmo de gradiente descendente por 15 iterações com uma taxa de aprendizado $\alpha = 0.3$ e computa a perda $J(\theta)$ após cada iteração. Você observa que o valor de $J(\theta)$ aumenta ao longo do tempo. Baseado nisso, qual das sentenças abaixo parece mais plausível.


1. $\alpha = 0.3$ é um valor efetivo de taxa de aprendizado.
2. Ao invés de se utilizar o valor corrente de α , é mais interessante aumentar seu valor (por exemplo, $\alpha = 1.0$).
3. Ao invés de se utilizar o valor corrente de α , é mais interessante diminuir seu valor (por exemplo, $\alpha = 0.1$).

1. Código-exemplo para Classificação

Assim como na lista de exercícios 1, será utilizado o conjunto de dados *cleveland.csv*, onde foi desenvolvido o código *código-exemplo-pca.py* para prever se uma pessoa terá ou não doença do coração. Neste código foi utilizado o algoritmo Naive Bayes sendo realizado um pré processamento de dados (uma vez que existem dados faltantes). Com os dados carregados e corrigidos, eles foram separados em treinamento (80%) e teste (20%). O resultado do treinamento e teste são apresentados nas matrizes de confusão da figura 2a e 2b,

respectivamente.

Figura 2. Matriz de confusão geradas para o treinamento (a) e para o teste (b) do classificador Naive Bayes.



(a) (b)



INSTITUTO FEDERAL
ESPÍRITO SANTO
Campus Serra

3

Reconhecimento de Padrões Exercício 02

2. ♦♦NN

Com o pré-processamento realizado, adapte o código-exemplo inserindo agora o algoritmo ♦♦NN e gere os resultados (matrizes de confusão) considerando ♦♦ = 3, 5 e 7. Utilize a distância euclidiana como métrica de distância.

3. Decision Tree

Adapte novamente o código-exemplo inserindo agora o algoritmo para a criação de uma árvore de decisão. Apresente os resultados do treinamento e teste seguindo o exemplo dado na figura 2.

4. Support Vector Machines

Adapte o código-exemplo e insira o algoritmo de máquina de vetores suporte. Considere, neste caso os kernels *linear* e *rbf* e apresente os resultados de treinamento e teste como na figura 2. Com a matriz de entrada reduzida pelo PCA (somente os dois primeiros *scores*), plote a curva de aprendizado do algoritmo treinado, como aparece na figura 3 (https://scikit-learn.org/stable/auto_examples/model_selection/plot_learning_curve.html). Neste caso utilize somente os dados de treinamento e o algoritmo com *kernel* RBF.

Figura 3. Exemplo de curva de aprendizado de um algoritmo do tipo SVM.

O arquivo “cnn_mnist.ipynb” carrega a base de dados MNIST e constrói uma CNN básica para classificação. Neste caso foram utilizadas duas abordagens: **holdout** e **validação cruzada com k-folds**. Rode o arquivo e faça:

1. Explique o que observou ao comparar as abordagens de holdout e validação cruzada.
2. Teste o modelo alterando parâmetros como o número de filtros na CNN e o tamanho do batch.
3. Discuta os impactos da escolha de holdout ou validação cruzada em projetos com diferentes tamanhos de dados.